昨 日 AI 重 点 资 讯

2026 年 10 月 14 日 星期三 | 第 001 期 | 收录窗口：10 月 13 日（含 12 日晚间）新进入大众视野的 AI 内容

［栏目一 · AI + 科研］

AI 自主解出 9 个悬置数十年的数学难题，这次走了同行评审

英文 | 阅读约 8 分钟 | **爆火时间点**：10 月 12—13 日中文圈集中讨论（10 月 10 日 X 上一则总结帖约 4.56 万次浏览，为第二波传播） | **实际发生**：论文 10 月 8 日发表于《Science》，预印本 5 月 21 日上线

Google DeepMind 的 AlphaProof Nexus 登上了《Science》。它做的事可以概括成一个「生成—校验」死循环：Gemini 3.1 Pro 在形式化语言 Lean 里起草证明，Lean 编译器逐行检查，报错回喂，模型修订，再校验。Lean 是一种把证明写得足够精确、让计算机能逐步核对的数学语言——编译通过，逻辑正确性由机器保证，模型没有「自说自话」的空间。

成绩：353 个开放 Erd s 问题中自主解决 9 个，其中 #12(i)(ii) 由 Erd s 与 Sárközy 于 1970 年提出、悬置 56 年；另证明 44/492 个 OEIS（在线整数数列百科）猜想、改进 min-max 优化的一个已知界，并解决 2 个 Hilbert 函数开放问题。论文口径成本为每道已解题「数百美元」量级。

值得打折的地方同样公开可查：9/353 约 2.5%，能啃的只是很小一片；模型曾「引用」文献中不存在的引理（被 Lean 的 sorry 标记拦下）；#125 与 #741(i) 的证明利用了「密度」表述的歧义，非正式命题随后被改写——论文称之为「发现并修正形式化错误」，批评者 Wegner 则认为是钻了模糊表述的空子（属非同行评审的个人观点）。erdosproblems.com 还记录 #741、#846 也被 OpenAI 内部模型独立解出。

更关键的消融实验：更朴素的「基础版 agent」独立复现了全部 9 个 Erd s 结果，只在最难的题目上成本更高——提示瓶颈在模型能力，而非 agent 架构的花样。

重点看：论文把形式化验证定位成「用来决定哪些证明值得人去看的过滤器」，而不是替代数学家。对比 OpenAI 此前把大量 AI 生成证明直接堆到 GitHub、引发数学界抵制的做法，这次可信度的差异主要来自「机器可查证 + 期刊审稿」这两道闸。

来源：Science 论文 doi.org/10.1126/science.aej2213 | EurekAlert 新闻稿 eurekalert.org/news-releases/1146436 | 全部 Lean 证明仓库 github.com/google-deepmind/alphaproof-nexus-results | InfoQ 中文解读 xie.infoq.cn/article/71a5d1dee3a391ddfbcfd632e

［栏目二 · AI + 游戏 / 产业实践］

Epic 对迪士尼新作下达「不再手写代码」，同一周另一份研究说：软件没变多

中英 | 阅读约 7 分钟 | **爆火**：10 月 13 日 | **实际发生**：内部指令上周宣布，10 月 13 日公开

Bloomberg 看到的内部消息：Epic 与迪士尼合作、含 Marvel 与 Star Wars 角色的未公开射击游戏被要求转为AI-first 生产——一位项目总监对员工说「no more hand-written code」，美术走「full AI workflows」，人改为引导与审核 Claude 等模型的产出。原定 2027 年 3 月，现无限期延期。Tim Sweeney 确认「a huge pivot」，称目标不是用更少的人做同样的事。

同一周，哈佛 Fiona Chen 与 James Stratton 基于 Jellyfish 遥测（700+ 家公司、70 万余名员工、约 3 亿条工作事件，2021–2026/3）给出另一半：引入编码 agent 后代码行数 +30%、提交 +20%、PR +23%，但 Jira 上 issue/epic 解决率无统计显著变化；PR 合并耗时 +49%，要求修改的比例近乎翻倍，评论数 +35%。到 2026 年 3 月 80% 公司已用 AI 代码审查，但 AI 只写了 23.3% 的评审评论。

判断：Epic 的赌注是人的劳动从「亲手实现」转向「规格、筛选、校验、修复」；哈佛数据说明这条路的收益不自动兑现。还要注意因果顺序——项目本就因人手与周期被低估而落后，AI 转向是被引入一个已有麻烦的排期，而非 AI 导致延期。

来源：arstechnica.com/gaming/2026/10/report-epic-games-goes-all-in-on-ai-for-disney-collaboration | theverge.com/games/1010097 | 哈佛研究（Ars）arstechni.ca/UKyJ

［栏目三 · AI 安全］

模型能把任意能力「加密上锁」藏进权重，评估查不出来

英文 | 阅读约 6 分钟 | **爆火**：10 月 13 日 | **实际发生**：arXiv 10 月 9 日提交，已被 NeurIPS 2026 接收

《AI Models Can Provably Hide Arbitrary Capabilities》做了件此前做不到的事：过去只能把固定字符串藏进模型权重，这篇把一整个加密的神经网络藏进去，只有收到秘密触发器时才解密并执行。

用的工具叫 digital locker（数字锁柜）：用一个密钥锁住一段消息，只有正确密钥才返回内容，错的返回失败值。这里「密钥」是秘密触发器、「消息」是被藏模型的权重——触发器熵足够高时，猜中在计算上不可行。要把「算法」变成「神经网络」，作者走了一条编译链：算法 → 直线程序（无分支的固定操作序列）→ 线性阈值电路 → 用 GLU 模块表示成矩阵，适配 transformer。所以被藏的不是夹带的文件，而是织进模型数值结构里的计算。实验用两个小规模模型体（子集奇偶；化学反应可合成性分类，作为 CBRN 相关能力的保守替身）；微调、权重加噪、梯度触发器搜索、隐变量对抗训练四种方法都没打出来。

重点看：论文没有主张「某个已部署模型藏了东西」，而是给出一条上限——在既定构造与假设下，靠「引出」做能力审计存在无法用工程努力消除的盲区。这也给「检测锁柜结构而非引出触发器」指了方向。

来源：arxiv.org/abs/2610.13928 | getaibook.com/news/ai-models-provably-hide-capabilities-neurips | hitreader.com/post/the-secret-compartment-inside-an-ai-model

简 讯 · 未成稿但值得留档

- **Meta 首次拿出前沿模型 Muse Wonder / Wonder Full**（10/12 发布，10/13 中文媒体集中报道）：主打两个被训练进模型的行为——Active Memory（跨会话保留相关信息、按需取回）与 Active Focus（遇阻换路径、重要动作前先确认）。1M 上下文，闭源不开放权重。第三方智能指数 Full 56 / 标准 52（Claude Opus 5.5 为 58）；跑分均为厂商口径，无独立复核，安全报告未发。 about.fb.com/news/2026/10/introducing-muse-wonder-models

- **微软发布 Azure Maia 300，2027 年起成为主要推理系统**（10/12 官宣，10/13 中文报道）：台积电 N2P + chiplet + 8 组 HBM4，单加速器 288GB / 18TB/s；官方称每兆瓦 token 数比领先 GPU 系统高约 40%，96 卡整机柜吞吐最高为 Maia 200 的 7 倍；同期发布 agent 原生 CPU Cobalt 200（调用延迟降 33%）。 azure.microsoft.com（见 Azure 官方博客）

- **GitHub 10/13 趋势榜：agent 工具链在补「上下文治理」这一层**。mksglu/context-mode（工具输出沙箱化，称削减 98% 上下文占用，经 MCP + hooks 在 17 个平台间强制路由、持久化会话记忆，当日 +246 星）；Alishahryar1/free-claude-code（10 余个 harness 收进统一入口，当日 +626 星）。证据是 star 增速，不是转载量。 github.com/mksglu/context-mode

- **Cognition FrontierCode 1.1 排行榜**：测代码能否被真实维护者合并，Claude Opus 5.5 以 52% 居首，但所有模型失败率仍超 40%——与哈佛研究同向：会写代码不等于能交付。

- **DeepSeek 4.1 Flash 成本之争**（10/13 Hacker News 高热帖）：称 KV cache 相比 V1 缩小约 437 倍、「全天会话不到 1 美元」；主要反驳是「付的是折扣订阅费而非 API 原价」。属社区观点交锋，非独立核验数据。

- **Qwen 开源弹性强化学习框架 QwenGyre**：GPU 可在 rollout 与训练间动态调度，官方称 70 万 token 长任务 agent 训练提速最高 1.85 倍。

剔除说明：bilawalsidhu/gods-eye-view（真实数据的 3D 地球「卫星模拟器」）10 月 13 日确实再次登上 GitHub 日榜（+1895 星），但它已于 2026 年 8 月 27 日登顶 GitHub Trending 日榜与周榜，不属于「昨日新进入大众视野」，不收录。

本 期 收 录 口 径

收录标准不是「昨日发生」，而是「昨日（含前一日晚间）新进入大众视野、开始被大量讨论」。事件本身可能发生在数日前甚至更早，只要它在昨日刚刚爆火、出圈或首次被主流报道，即符合条件，因此每篇均同时标注**爆火时间点**与**事件实际发生时间**。单纯昨日发生但毫无传播热度的常规动态，本期不优先收录。**与《已收录简表》比对结果**：本期为该表建立后的第 001 期，简表原有记录为空，故不存在「同一事件重复收录」的剔除；唯一被剔除的候选为 gods-eye-view（理由见上）。

检 索 路 径 与 证 据 类 型

本期候选池来自：Hacker News 当日热帖、GitHub Trending 日榜 API 快照（10 月 13 日 15:00 北京时间）、《Science》与 EurekAlert 官方发布、Ars Technica / The Verge / The Verge 同源报道、Bloomberg 报道的权威转述（Ars Technica、VGC）、Artificial Analysis 第三方榜单、多家中文 AI 日报（AITOP、InfoQ、开源中国）。**证据分级**：「爆火」的判断依据按可核验程度排序——GitHub star 单日增量 ＞ 多家独立媒体同一日跟进 ＞ 社区热帖的讨论量与观点分布 ＞ 单一来源转述。凡只有厂商自述、缺少独立复核的数字，本期一律标注为「厂商口径」；只有社区观点交锋而无独立数据的，标注为「非独立核验数据」，不当作事实使用。文中已明确区分三件事：**可核实的事实**、**来源方的观点**（如论文作者的自我定位、批评者的质疑）、以及**本刊的判断**。所有链接均为直达原文，未使用搜索结果页或网站首页代替；涉及本刊未能直接取回原文的条目，已在下方信息缺口中逐条说明。

检索截止时间：2026 年 10 月 14 日 21:30（GMT+8）。**信息缺口**：①《Science》正文页对本次检索返回 HTTP 403，核心数字来自 EurekAlert 新闻稿、论文摘要与多家二手报道的交叉验证，卷号页码与接收日期未能直接核对；②Epic 原始 Bloomberg 稿件未直接获取，事实层来自 Ars Technica、The Verge、VGC 对同一份报道的转述，Epic 官方未公布新档期与节省时间的度量方式；③哈佛研究数据截至 2026 年 3 月，此后 agent 能力有显著变化，结论可能低估当前状态；④Muse Wonder 的跑分均为厂商口径，尚无独立第三方复核，安全评估报告截至检索时未发布；⑤简讯中的 FrontierCode 1.1、QwenGyre、DeepSeek 4.1 Flash 三条，原始出处分别为 Artificial Analysis 榜单页、阿里通义官方社交账号、Hacker News 讨论帖，本次未取回可长期引用的稳定直链，故仅标注来源类型、不附链接，请勿按最终来源引用；⑥本期未找到符合收录标准的「AI + 教育」与「新鲜 AI 玩法」条目，故未设这两个栏目，未做凑数填充。